



FCTUC FACULDADE DE CIÊNCIAS
E TECNOLOGIA
UNIVERSIDADE DE COIMBRA

Relatório - Music Information Retrieval

Trabalho Prático nº 2

Trabalho realizado por:

João Macedo 2021220627

Bruno Silva 2021232021

Diogo Honório 2021232043

Pedro Fernandes 2019218772

Índice

Introdução	3
Contexto e Objetivos	3
Metodologia	3
Preparação para a realização do Projeto - Exercício 1	4
Extração e Normalização de Features - Exercício 2	4
Exercício 2.1.....	4
Processo de Extração	4
Cálculo de Estatísticas para Características de Áudio	5
Normalização de Características de Áudio no Intervalo [0, 1].....	6
Exercício 2.2.....	7
Implementação do Centróide Espectral de Raiz	7
Comparação com Librosa e Análise de Erro	8
Exercício 3	9
Definição das Métricas de Similaridade:.....	9
Criação dos Rankings de cada Métrica:	9
Exercício 4	10
Exercício 4.1- Avaliação objetiva	10
Exercício 4.2 – Avaliação subjetiva	10

Introdução

Este relatório detalha o desenvolvimento e a análise de um sistema de recomendação de música baseado em conteúdo, realizado no âmbito do Trabalho Prático nº 2 da disciplina de Multimédia, sob orientação do professor Ricardo Correia Nascimento dos Santos. O objetivo central deste trabalho é permitir aos alunos adquirir conhecimentos e habilidades em Multimedia Information Retrieval, com foco específico em sistemas de recomendação que operam através de análises de conteúdo musical.

Contexto e Objetivos

O sistema de recomendação proposto procura explorar e automatizar a seleção musical com base em características intrínsecas das faixas, tais como timbre, ritmo, e harmonia, utilizando para isso o framework librosa para processamento de áudio. O projeto requer a implementação prática de métodos de extração de características (features), a aplicação de métricas de similaridade para comparar faixas musicais, e a construção de um modelo eficiente que possa sugerir músicas alinhadas às preferências do utilizador sem a intervenção humana direta.

Metodologia

A metodologia adotada envolve várias etapas cruciais:

1. Preparação de Dados: Download e análise de um conjunto de dados consistindo de 900 músicas do 4Q Audio Emotion Dataset.
2. Extração de Features: Utilização da biblioteca librosa para extrair múltiplas características espectrais e temporais das músicas.
3. ... Ainda por fazer

Preparação para a realização do Projeto - Exercício 1

A fase de preparação envolveu configurar o ambiente de desenvolvimento e as ferramentas necessárias para analisar e processar o dataset de músicas. Abaixo, destacamos as principais bibliotecas e dependências implementadas:

1.1. Bibliotecas e Dependências

Librosa: Utilizada para a análise e extração de características do áudio.

FFmpeg: Essencial para o processamento de arquivos MP3.

Sounddevice: Permitiu a reprodução de áudio no desenvolvimento.

1.2. Configuração Inicial

O dataset "4Q Audio Emotion Dataset" foi descarregado, incluindo 900 músicas em MP3 e metadados relevantes para as recomendações, todos os ficheiros Mp3 foram colocados no mesmo diretório para um processamento mais otimizado em código. A preparação inicial assegurou que todas as ferramentas necessárias estavam prontas para uso, facilitando as etapas de desenvolvimento seguintes do projeto.

Extração e Normalização de Features - Exercício 2

Exercício 2.1

Neste exercício, o objetivo era desenvolver um processo sistemático para a extração e manipulação de características (features) audiovisuais de ficheiros de música utilizando a biblioteca librosa em Python. O processo é dividido em várias etapas principais, detalhadas a seguir.

Processo de Extração

1. Carregamento do Áudio:

- Método: librosa.load
- Configuração: Mono, 22050 Hz.

2. Características Espectrais Extraídas:

- MFCC: 13 coeficientes, captura a forma espectral do som.
- Centróide Espectral: Indica o centro de massa do espectro.
- Largura de Banda Espectral: Mede a extensão das frequências principais.
- Contraste Espectral: Mede o contraste nas bandas espectrais ao longo de várias janelas, resultando em 7 valores por música (considerando 6 bandas).
- Platicidade Espectral (Flatness): Indica a "planicidade" do espectro.
- Rolloff Espectral: Frequência sob a qual está concentrada uma percentagem da energia.

3. Características Temporais Extraídas:

- RMS Energy: Reflete a magnitude média do sinal.
- Taxa de Cruzamentos por Zero: Frequência de mudanças de sinal.
- Frequência Fundamental (F0): Menor frequência de vibração de um som.

4. Outras Características:

- Tempo (BPM): Ritmo da música em batidas por minuto.

A função `extract_features` extrai características relevantes para a classificação de áudio e outras análises, utilizando `librosa` para facilitar o processamento e análise de dados de áudio. Estas informações são vitais para modelar e melhorar a precisão de tarefas preditivas baseadas em som.

Cálculo de Estatísticas para Características de Áudio

Neste projeto, a análise de características de áudio é realizada por meio da função `calculateStatistics`, que processa dados provenientes de arquivos de áudio. O objetivo é calcular sete estatísticas descritivas fundamentais que são: média, desvio padrão, assimetria (skewness), curtose, mediana, máximo e mínimo. Essas estatísticas são cruciais para entender a distribuição e a natureza das características de áudio.

Função `calculateStatistics`

Esta função aceita um dicionário onde as chaves representam os nomes das características e os valores são os dados associados, que podem variar em dimensionalidade. As características es-

peciais, como 'mfcc' (coeficientes cepstrais de frequência mel) e 'spectral_contrast' (contraste espectral), são arrays 2D onde cada linha representa uma dimensão distinta e necessita de um cálculo individual de estatísticas. Por outro lado, características como 'tempo' são representadas por um único valor escalar.

Para cada característica, a função determina o formato adequado para processamento e passa os dados para a função `compute_stats`. Esta função auxiliar é responsável por calcular as sete estatísticas descritivas mencionadas acima para cada conjunto de dados. Os resultados são então agregados em um array do NumPy.

Detalhes da Implementação

A implementação eficiente utiliza loops para iterar sobre cada característica e condicionais para tratar diferentes tipos de dados de entrada. Após o cálculo das estatísticas, esses valores são estendidos a uma lista principal que, ao final do processo, é convertida em um array 2D do NumPy. Este array possui uma linha por música e uma coluna por cada estatística calculada de cada característica, totalizando 190 características por arquivo, conforme configurado.

O array final `all_features` armazena as estatísticas de cada arquivo de áudio processado, facilitando análises futuras.

Normalização de Características de Áudio no Intervalo [0, 1]

Descrição do Processo

No contexto deste projeto, a normalização das características de áudio é essencial para garantir que os dados estejam na mesma escala, facilitando a análise comparativa e a aplicação de técnicas de aprendizado de máquina. A normalização é realizada pela função `normalize_np`, que ajusta as características para o intervalo [0, 1]. Esse procedimento é crucial para eliminar quaisquer discrepâncias de escala entre diferentes tipos de dados.

Função `normalize_np`

Esta função transforma as características extraídas de arquivos de áudio, normalizando cada característica de acordo com os valores mínimo e máximo observados.

Para garantir a robustez, a função verifica se a diferença entre os valores máximo e mínimo é zero (o que poderia levar a uma divisão por zero), substituindo essa diferença por 1 quando necessário.

Estrutura da Matriz Normalizada

A matriz resultante é composta por `count + 2` linhas, onde `count` é o número de arquivos de áudio processados. As duas primeiras linhas armazenam os valores mínimos e máximos de cada característica, respectivamente, seguidas pelas linhas que contêm as características normalizadas dos arquivos de áudio.

Implementação

No contexto do script, `all_features` é uma matriz que armazena as estatísticas calculadas de cada arquivo de áudio. A função `normalize_np` é chamada após todas as características serem calculadas e armazenadas em `all_features`. A função processa até `max_files` arquivos, garantindo que todos os dados sejam tratados uniformemente antes da normalização.

Após a normalização, os resultados são salvos em arquivos CSV para validação posterior e análise, incluindo as características originais e normalizadas. Este passo é crítico para a validação dos resultados da normalização, assim como para análises subsequentes.

Exercício 2.2

Nesta seção, descreveremos o processo de implementação da característica de centroide espectral utilizando apenas as bibliotecas Numpy e Scipy, sem o auxílio de bibliotecas externas como a librosa, que é comumente utilizada para essa finalidade. Além disso, compararemos os resultados obtidos com os da biblioteca librosa usando métricas de erro, como o coeficiente de correlação de Pearson e o RMSE (Root Mean Square Error), para assegurar a precisão da implementação.

Implementação do Centroide Espectral de Raiz

Metodologia

A função `spectral_centroid_root` foi desenvolvida para calcular o centroide espectral de um sinal de áudio sem utilizar a biblioteca librosa. O processo envolve a leitura do arquivo de áudio, a aplicação de uma janela temporal ao sinal, e a utilização da Transformada Rápida de Fourier (FFT) para obter o espectro de magnitude do sinal. O centroide espectral é então calculado como a média ponderada das frequências presentes no espectro, ponderada pela magnitude em cada ponto de frequência.

Implementação

Carregamento e Preparação do Sinal: O sinal de áudio é carregado e, se necessário, é preenchido com zeros para garantir que a última janela de análise contenha dados suficientes. A função

`np.pad` é usada para adicionar zeros quando o comprimento do sinal não é suficiente para completar a última janela.

Aplicação da Janela Temporal: Utiliza-se uma função de janela de Hanning para minimizar os vazamentos espectrais. Cada segmento do sinal é multiplicado por esta função de janela antes da aplicação da FFT.

Cálculo do Espectro de Magnitude: A transformada rápida de Fourier é aplicada usando `scipy.fft.rfft`, gerando o espectro de magnitude para cada janela temporal.

Cálculo do Centroide Espectral: O centroide espectral é calculado para cada janela como a soma do produto das frequências pelo espectro de magnitude, dividido pela soma do espectro de magnitude. A verificação de que a soma do espectro de magnitude é maior que zero é crucial para evitar divisão por zero.

Parâmetros Usados

Tamanho da Janela: 2048

Comprimento do Passo (Hop Length): 512

Taxa de Amostragem: 22050 Hz (fixa, conforme configuração inicial da função de extração)

Comparação com Librosa e Análise de Erro

Após a implementação da função `spectral_centroid_root`, os resultados são comparados com os valores obtidos pela função equivalente da biblioteca `librosa`. Para isso, utiliza-se o coeficiente de correlação de Pearson e o RMSE (Root Mean Square Error) como métricas de erro para avaliar a precisão da implementação proposta em relação à implementação de referência.

Armazenamento e Validação dos Resultados

Os resultados das métricas de erro são armazenados em um arquivo CSV para posterior análise e validação. O código assegura que os arrays de centroide espectral (tanto o implementado quanto o de `librosa` ajustado para o atraso de duas janelas) tenham o mesmo tamanho para uma comparação justa.

Exercício 3

Neste exercício, o objetivo foi calcular diferentes métricas de similaridade entre a query e os arquivos de áudio utilizando a biblioteca NumPy. Foram implementadas três métricas distintas: distância Euclidiana, distância de Manhattan e similaridade do Cosseno. Cada métrica foi representada por uma função específica: `euclidean_distance`, `manhattan_distance` e `cosine_similarity`, respectivamente.

Ao calcular essas métricas, foi importante considerar as características específicas de cada uma delas. Por exemplo, a distância Euclidiana é responsável por medir a distância direta entre dois pontos em um espaço euclidiano, enquanto a distância de Manhattan tem como função medir a soma das diferenças absolutas entre as coordenadas dos pontos. Por fim a similaridade do Cosseno calcula o cosseno do ângulo entre dois vetores, sendo útil para comparar a direção dos vetores independentemente de sua magnitude.

Definição das Métricas de Similaridade:

Para a implementação das métricas são definidas três funções para calcular diferentes para calcular cada uma delas (`euclidean_distance` / `manhattan_distance` / `cosine_similarity`), estas funções recebem como parâmetros as features da query base e as features de um dos 900 files que está a ser analisado. Estas distâncias são calculadas e os índices das mesmas foram armazenados em arrays para análise posterior. Além disso, uma versão em formato CSV foi criada para cada métrica, permitindo uma análise detalhada dos resultados.

Criação dos Rankings de cada Métrica:

Na criação dos rankings ordenamos o array com todas as distâncias por ordem crescente e apenas colocar os 11 resultados mais baixos no ranking onde o primeiro elemento pois corresponde à query. Esses índices dos arquivos selecionados foram então usados para obter os nomes das músicas e as suas distâncias correspondentes.

Analise e discussão dos Resultados

Após analisarmos os rankings gerados utilizando as métricas de distância Euclidiana, Manhattan e Cosseno, notamos que 5 das 10 músicas listadas são comuns aos três rankings. Ao compararmos essas músicas com outras nos rankings, encontramos algumas que são bastante semelhantes, enquanto outras não apresentaram relação aparente. Essa variação sugere que, embora as métricas possam identificar tendências gerais de similaridade, elas também podem capturar diferentes aspectos ou características das músicas.

Exercício 4

No exercício 4 é pedido para fazermos a avaliação tanto objetiva, usando metadados dos ficheiros *panda_dataset_taffc_metadata.csv* e *query_metadata.csv* para determinar se os rankings obtidos no exercício 3 são relevantes perante a música original, assim como subjetiva, em que os elementos do grupo fazem a análise das músicas e as analisam perante a proximidade da música original.

Exercício 4.1- Avaliação objetiva

Neste exercício, obtivemos o ranking de músicas com base na correspondência com os metadados seguintes: artista, género e emoção, tendo em conta os metadados presentes nos ficheiros *panda_dataset_taffc_metadata.csv* e *query_metadata.csv*.

Analise e discussão dos Resultados

Com base nestes metadados é possível obter que em todos os rankings de similaridade possuímos uma **precision** de 20%, isto deve-se a que só determinadas músicas sejam iguais em todos os rankings ('MT0000040632.mp3', 'MT0003949060.mp3').

Exercício 4.2 – Avaliação subjetiva

Distância Euclidiana

Retrieved Docs	Bruno	Diogo	João	Pedro	MEAN	STD
MT0003949060	4	5	4	5	4,5	0,5
MT0004274911	2	2	1	2	1,75	0,433
MT0001515531	1	1	1	1	1	0
MT0000040632	3	4	4	4	3,75	0,433
MT0003900455	3	2	2	2	2,25	0,433
MT0009897495	2	3	2	2	2,25	0,4
MT0004032071	1	2	3	1	1,75	0,829
MT0005469880	4	4	4	3	3,75	0,433
MT0007043936	2	3	2	2	2,25	0,4
MT0034005433	2	3	3	3	2,75	0,433
MEAN	2,4	2,9	2,6	2,5	2,6	
STD	1,02	1,14	1,11	1,20	1,12	
Distancia Eucladiana						

MT0003949060 – Nota 4.5 (semelhanças no ritmo, voz e estilo de música)
 MT0004274911 – Nota 1.75 (ritmo semelhante, estilo diferente da original)
 MT0001515531 – Nota 1 (Muito diferente da original)
 MT0000040632 – Nota 3.75 (semelhante no ritmo e no estilo)
 MT0003900455 – Nota 2.25 (semelhante no ritmo)
 MT0009897495 – Nota 2.25 (semelhante no estilo)
 MT0004032071 – Nota 1.75 (semelhante no ritmo)
 MT0005469880 – Nota 3.75 (semelhante no ritmo)
 MT0007043936 – Nota 2.25 (semelhante no estilo)
 MT0034005433 – Nota 2.75 (semelhante no estilo e ritmo)

Precisão: 40%

Distância de Manhattan

Retrieved Docs	Bruno	Diogo	João	Pedro	MEAN	STD
MT0003949060	4	5	4	5	4,5	0,5
MT0004274911	2	2	1	2	1,75	0,433
MT0000040632	3	4	4	4	3,75	0,433
MT0000218346	1	1	1	1	1	0
MT0003900455	3	2	2	2	2,25	0,433
MT0005469880	4	4	4	4	4	0
MT0008401073	2	3	3	3	2,75	0,433
MT0034125967	3	4	3	3	3,25	0,433
MT0001515531	1	1	1	1	1	0
MT0001624303	1	1	1	1	1	0
MEAN	2,4	2,7	2,4	2,6	2,5	
STD	1,11	1,42	1,28	1,36	1,29	
Distancia de Manhattan						

MT0003949060 – Nota 4.5 (semelhanças no ritmo, voz e estilo de música)
 MT0004274911 – Nota 1.75 (ritmo semelhante, estilo diferente da original)
 MT0000040632 – Nota 3.75 (semelhante no ritmo e no estilo)
 MT0000218346 – Nota 1 (Muito diferente da original)
 MT0003900455 – Nota 2.25 (semelhante no ritmo)
 MT0005469880 – Nota 3.75 (semelhante no ritmo)
 MT0008401073 – Nota 2.75 (semelhante no ritmo)
 MT0034125967 – Nota 3.25 (semelhante no ritmo)
 MT0001515531 – Nota 1 (Muito diferente da original)
 MT0001624303 – Nota 1 (Muito diferente da original)

Precisão: 50%

Distância do Coseno

Retrieved Docs	Bruno	Diogo	João	Pedro	MEAN	STD
MT0004274911	2	2	1	2	1,75	0,433
MT0003949060	4	5	4	5	4,5	0,5
MT0001515531	1	1	1	1	1	0
MT0001942272	2	2	1	1	1,5	0,500
MT0002634024	3	2	2	2	2,25	0,433
MT0003900455	3	2	2	2	2,25	0,433
MT0000040632	3	4	4	4	3,75	0,433
MT0009897495	2	3	2	3	2,5	0,5
MT0004032071	1	2	3	1	1,75	0,829
MT0005752234	4	4	4	4	4	0
MEAN	2,5	2,7	2,4	2,5	2,5	
STD	1,02	1,19	1,20	1,36	1,19	
Distancia de Cosseno						

MT0004274911 – Nota 1.75 (ritmo semelhante, estilo diferente da original)

MT0003949060 – Nota 4.5 (semelhanças no ritmo, voz e estilo de música)

MT0001515531 – Nota 1 (Muito diferente da original)

MT0001942272 – Nota 1.5 (Estilo diferente do original)

MT0002634024 – Nota 2.25 (Ritmo semelhante)

MT0003900455 – Nota 2.25 (semelhante no ritmo)

MT0000040632 – Nota 3.5 (semelhante no ritmo e no estilo)

MT0009897495 – Nota 2.25 (semelhante no estilo)

MT0004032071 – Nota 1.75 (semelhante no ritmo)

MT0005752234 – Nota 4 (semelhanças no ritmo e estilo de música)

Precisão: 40%

Metadados

Retrieved Docs	Bruno	Diogo	João	Pedro	MEAN	STD
MT0027048677	5	4	5	5	4,75	0,433
MT0010489498	5	5	5	5	5	0
MT0010487769	3	4	4	4	3,75	0,433
MT0033397838	4	4	3	4	3,75	0,433
MT0003949060	4	5	4	5	4,5	0,5
MT0012331779	5	5	5	5	5	0
MT0000040632	3	4	4	4	3,75	0,433
MT0002222957	5	5	5	5	5	0
MT0008222676	3	4	4	3	3,5	0,500
MT0010900969	1	2	3	2	2	0,707
MEAN	3,8	4,2	4,2	4,2	4,1	
STD	1,25	0,87	0,75	0,98	0,96	
Ranking Metadados						

MT0027048677 - Nota 4.75 (semelhanças no ritmo, voz e estilo de música)
MT0010489498 - Nota 5 (semelhanças no ritmo, voz e estilo de música)
MT0010487769 - Nota 3.75 (semelhanças no ritmo, voz e estilo de música)
MT0033397838 - Nota 3.75 (semelhanças no ritmo e estilo de música)
MT0003949060 - Nota 5 (semelhanças no ritmo, voz e estilo de música)
MT0012331779 - Nota 5 (semelhanças no ritmo, voz e estilo de música)
MT0000040632 – Nota 3.75 (semelhante no ritmo e no estilo)
MT0002222957 - Nota 5 (semelhanças no ritmo, voz e estilo de música)
MT0008222676 - Nota 3.5 (semelhante no ritmo e no estilo)
MT0010900969 – Nota 2 (semelhante no estilo)

Precisão: 90%